



Flow Matching

参考

[Continuous Normalizing Flows](#)

[Normalizing Flows](#)

[Continuous Normalizing Flows](#)

[Continuity Equation](#)

[Conditional and Marginal Probability Paths and Vector Fields](#)

[Conditional and Marginal Probability Paths and Vector Fields](#)

[Calculate Conditional Probability Paths and Conditional Vector Fields](#)

[Conditional Flow Matching](#)

[Flow Matching](#)

[Conditional Flow Matching](#)

[Diffusion conditional Vector Fields and Optimal Transport conditional Vector Fields](#)

[Diffusion conditional Vector Fields](#)

[Optimal Transport conditional Vector Fields](#)

Continuous Normalizing Flows


CNFs是一种用于描述连续的变量变换的数学工具

Normalizing Flows

给定随机变量 z ，其pdf为 $\pi(z)$ ，设 $x = f(z)$ ，则 x 的pdf为

$$p(x) = \pi(f^{-1}(x)) \det \frac{df^{-1}}{dx}$$

通过一系列可逆的概率密度变换，将简单的分布映射到复杂的分布



设 p_0 为原始分布，经过一系列可逆变换 $\{f_i\}$ ：

$$x = z_K = f_K \circ f_{K-1} \circ \cdots \circ f_1(z_0)$$

也就是说

$$z_i = f_i(z_{i-1})$$

于是，我们有

$$\begin{aligned} p_i(z_i) &= p_{i-1}(f_i^{-1}(z_i)) \left| \det \frac{df_i^{-1}}{dz_i} \right| \\ &= p_{i-1}(z_{i-1}) \left| \det \left(\frac{df_i}{dz_{i-1}} \right)^{-1} \right| \\ &= p_{i-1}(z_{i-1}) \left| \det \frac{df_i}{dz_{i-1}} \right|^{-1} \end{aligned}$$

取对数得

$$\log p_i(z_i) = \log p_{i-1}(z_{i-1}) - \log \left| \det \frac{df_i}{dz_{i-1}} \right|$$

展开直到原始分布

$$\log p(x) = \log p_K(z_K) = \log \pi_0(z_0) - \sum_{i=1}^K \log \left| \det \frac{df_i}{dz_{i-1}} \right|$$

模型训练时，目标为最大化对数似然 $\log p(x)$

Continuous Normalizing Flows

CNFs为NFs的连续推广，变量的连续变换通过ODE来描述

$$\frac{dz_t}{dt} = v(z_t, t)$$

其中 $t \in [0, 1]$, z_t 为 Flow Map, $v(z_t, t)$ 为向量场, 用于描述数据点的变化趋势, 通常由神经网络预测

给定一个初始分布, $\mathbf{v}(\mathbf{z}_t, t)$ 可以给出这个分布随时间的演变情况, 最终达到目标分布

该 ODE 可通过数值方法估计

$$z_{t+\Delta t} = z_t + \Delta t \cdot v(z_t, t)$$

Continuity Equation

用于描述守恒量的传输行为

设有流体, 密度为 ρ , 速度场为 \mathbf{v} , 则任取体积 \mathcal{V} , 单位时间流出 \mathcal{V} 的流体质量等于其内流体质量的减少量, 结合散度定理有

$$\begin{aligned} \int_{\mathcal{S}} \rho \mathbf{v} \cdot d\mathbf{S} + \frac{\partial}{\partial t} \int_{\mathcal{V}} \rho dV &= 0 \\ \int_{\mathcal{V}} \nabla \cdot (\rho \mathbf{v}) dV + \int_{\mathcal{V}} \frac{\partial}{\partial t} \rho dV &= 0 \\ \frac{\partial}{\partial t} \rho + \nabla \cdot (\rho \mathbf{v}) &= 0 \end{aligned}$$

由于概率密度总和为1, 因此**概率守恒**, 将 ρ 替换为 pdf p_t , 流速场替换为概率密度流 \mathbf{v}_t , 得

$$\frac{\partial p_t(x)}{\partial t} + \nabla \cdot [p_t(x) \mathbf{v}_t(x)] = 0 \quad (1)$$

注意: Fokker-Plank Equation 为 Continuity Equation 的推广!

性质: Vector Field $\mathbf{v}_t(\mathbf{x})$ 与 $\mathbf{p}_t(\mathbf{x})$ 满足(1)当且仅当 $\mathbf{v}_t(\mathbf{x})$ 生成概率密度路径 $\mathbf{p}_t(\mathbf{x})$

Conditional and Marginal Probability Paths and Vector Fields

Conditional and Marginal Probability Paths and Vector Fields

现在的问题来到给定初始分布 p_0 ，如何求向量场 u_t ，使得 p_0 生成 $p_t \rightarrow q, t \rightarrow 1$

考虑条件概率流 $u(x|x_1)$ ，其中 x_1 为数据空间中具体的数据样本，其生成条件概率密度路径 $p_t(x|x_1)$ [两者满足(1)]，定义边缘概率密度路径

$$p_t(x) = \int p_t(x|x_1)q(x_1)dx_1 \quad (2)$$

再通过对条件向量场的积分得到边缘向量场

$$u_t(x) = \int u_t(x|x_1) \frac{p_t(x|x_1)q(x_1)}{p_t(x)} dx_1 \quad (3)$$

则 $u_t(x)$ 生成 $p_t(x)$

现在，只需要设计 $u(x|x_1)$ 或 $p_t(x|x_1)$ ，使得 $p_1(x) \approx q(x)$ 即可解决上述问题
由于

$$p_1(x) = \int p_1(x|x_1)q(x_1)dx_1$$

令 $p_1(x|x_1) = \delta(x_1 - x)$ ，则有

$$p_1(x) = \int \delta(x_1 - x)q(x_1)dx_1 = q(x)$$

此时， u_t 生成的概率密度 p_t 路径将收敛于 q

Summary:

1. 定义 $p_t(x|x_1)$ ，使得 $p_1(x|x_1) = \delta(x_1 - x), p_0(x|x_1) = p_0(x), \forall x_1 \in \mathcal{X}$
2. 利用(1)求出对应条件向量场 $u_t(x|x_1)$
3. 利用(2)(3)求出边缘向量场 $u_t(x)$
4. p_0 在 u_t 下演变至 q

Calculate Conditional Probability Paths and Conditional Vector Fields

考虑高斯条件概率路径

$$p(x|x_1) = \mathcal{N}(\mu_t(x_1), \sigma_t(x_1))$$

满足

$$\begin{aligned}\mu_0 &= 0, \sigma_0 = 1 \\ \mu_1 &= 0, \sigma_1 \approx 0\end{aligned}$$

则其满足上述边值条件 $p_1(x|x_1) = \delta(x_1 - x), p_0(x|x_1) = p_0(x), \forall x_1 \in \mathcal{X}$

其对应的Flow Map为

$$\psi_t(x|x_1) = \sigma_t(x_1)x + \mu_t(x_1)$$

代入(1)($z_t \leftarrow \psi_t(x|x_1)$)得到闭式解

$$u_t(x|x_1) = \frac{\sigma'_t(x_1)}{\sigma_t(x_1)}[x - \mu_t(x_1)] + \mu'_t(x_1)$$

Conditional Flow Matching

尽管已经求得 $u_t(x|x_1)$ ，但求 $u_t(x)$ 依旧是Intractable的(积分包含未知分布 q)，此时，就需要依赖作者提出的Conditional Flow Matching技术

Flow Matching

拟合 q 已经被转化为可以生成 q 的概率密度向量场 u_t ，令 v_t 为由NN参数化的向量场，目标为估计 u_t

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t, p_t(x)} \|u_t(x) - v_t(x)\|^2$$

问题是： $u_t(x)$ 是Intractable的

Conditional Flow Matching

$u_t(x)$ Intractable，但 $u_t(x|x_1)$ 确是已知

考虑Conditional Flow Matching Loss

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, q(x_1), p_t(x|x_1)} \|u_t(x|x_1) - v_t(x)\|^2$$

$$\begin{aligned}
\nabla_{\theta} L_{CFM}(\theta) &= \nabla_{\theta} E_{t, p_t(x|z), q(z)} \|v_{\theta}(t, x) - u_t(x|z)\|^2 \\
&= \nabla_{\theta} E_{t, p_t(x|z), q(z)} \left[v_{\theta}(t, x)^2 - 2 \cdot v_{\theta}(t, x) \cdot u_t(x|z) + u_t(x|z)^2 \right] \\
&= \nabla_{\theta} E_{t, p_t(x|z), q(z)} \left[v_{\theta}(t, x)^2 \right] - 2 \nabla_{\theta} E_{t, p_t(x|z), q(z)} [v_{\theta}(t, x) \cdot u_t(x|z)]
\end{aligned}$$

类似的，我们考察(4)式对于 θ 的导数，有

$$\begin{aligned}
\nabla_{\theta} L_{FM}(\theta) &= \nabla_{\theta} E_{t, p_t(x)} \|v_{\theta}(t, x) - u_t(x)\|^2 \\
&= \nabla_{\theta} E_{t, p_t(x)} \left[v_{\theta}(t, x)^2 \right] - 2 \nabla_{\theta} E_{t, p_t(x)} [v_{\theta}(t, x) \cdot u_t(x)]
\end{aligned}$$

所以现在的关键在于，以上两个式子的右边第二项有什么联系？我们继续化简

$$\begin{aligned}
&\nabla_{\theta} E_{t, p_t(x)} [v_{\theta}(t, x) \cdot u_t(x)] \\
&= \nabla_{\theta} \int \int v_{\theta}(t, x) u_t(x) p_t(x) dx dt \\
&= \nabla_{\theta} \int \int v_{\theta}(t, x) \left[\int \frac{u_t(x|z) p_t(x|z)}{p_t(x)} q(z) dz \right] p_t(x) dx dt \\
&= \nabla_{\theta} \int \int \int v_{\theta}(t, x) u_t(x|z) p_t(x|z) q(z) dx dt dz \\
&= \nabla_{\theta} E_{t, p_t(x|z), q(z)} [v_{\theta}(t, x) \cdot u_t(x|z)]
\end{aligned}$$

以上推导使用了 $u_t(x)$ 的定义(7)以及期望的积分定义，所以这就巧了，我们发现


$$\nabla_{\theta} L_{FM}(\theta) = \nabla_{\theta} L_{CFM}(\theta)$$

也就是说， \mathcal{L}_{FM} 与 \mathcal{L}_{CFM} 有相同的极小值!!!


因此，我们将Intractable的FM转化为CFM，只要 $v_t(x)$ 最小化 \mathcal{L}_{CFM} ，则 $v_t(x)$ 成功拟合 $u_t(x)$
于是，在得到 $v_t(x)$ 后，即可通过数值求解对应的概率密度变换ODE来将 p_0 变换为目标分布 q

Diffusion conditional Vector Fields and Optimal Transport conditional Vector Fields

通过设计不同的Flow Map(也就是 μ_t, σ_t)，可以得到不同的概率密度路径



Diffusion



OT 知乎 @笑书神侠

Diffusion conditional Vector Fields

- **Variance Exploding (VE)**

在扩散过程中逐步增大数据噪声(能量变大), 也就是增大方差, 数据会逐渐变得嘈杂
有利于探索更广阔的隐空间, 使生成的样本更加多样化

$$p_t(x|x_1) = \mathcal{N}(x_1, \sigma_{1-t}^2 \mathbf{I})$$

其中 σ_t 为满足 $\sigma_0 = 0, \sigma_1 \gg 1$ 的单增函数

对应

$$u_t(x|x_1) = -\frac{\sigma'_{1-t}}{\sigma_{1-t}}(x - x_1)$$

- **Variance Preserving (VP)**

保持数据整体方差不变, 用于需要保持数据分布稳定性的场景, 如保持图像清晰度和结构特征

$$p_t(x|x_1) = \mathcal{N}(\alpha_{1-t}x_1, (1 - \alpha_{1-t}^2)\mathbf{I})$$

对应

$$u_t(x|x_1) = \frac{\alpha'_{1-t}}{1 - \alpha_{1-t}^2}(\alpha_{1-t}x - x_1) = -\frac{T'(1-t)}{2} \left[\frac{e^{-T(1-t)}x - e^{-\frac{1}{2}T(1-t)}x_1}{1 - e^{-T(1-t)}} \right]$$

训练更稳定

Optimal Transport conditional Vector Fields

简单定义条件概率路径为均值与标准差为时间的线性函数

$$\mu_t(x_1) = tx_1, \sigma_t(x) = 1 - (1 - \sigma_{\min})t$$

对应Flow Map

$$\psi_t(x) = (1 - (1 - \sigma_{\min})t)x + tx_1$$

条件向量场闭式解为

$$u_t(x|x_1) = \frac{x_1 - (1 - \sigma_{\min})x}{1 - (1 - \sigma_{\min})t}$$

训练速度更快