



Score-Matching, SDE, Langevin Dynamics Sampling

参考: [向diffusion更深处: score matching、随机微分方程和朗之万动力学](#) - 知乎

[Score Matching](#)

[Langevin Dynamics Sampling](#)

[Langevin Dynamics](#)

[退化分布与Noise Conditional Score](#)

[Annealed Langevin Dynamics](#)

[SDE视角下的Diffusion](#)

[Ito process](#)

[Score的求解](#)

[DDPM的SDE推导](#)

[逆向 SDE的求解](#)

[Conditional Generation](#)

Score Matching

假如我们的目标是利用NN拟合目标概率分布

$$p(x) = \frac{e^{-f(x)}}{Z}$$

假设 $f_\theta(x)$ 为NN的输出, 为了构造合法的概率密度函数, 我们令

$$p_\theta(x) = \frac{e^{-f_\theta(x)}}{Z_\theta}$$

其中 $Z_\theta = \int e^{-f_\theta(x)} dx$ 为归一化因子, 非常难以求解, 如何绕过?

答: 使用Score Function $s_\theta(x) = \nabla_x \log p_\theta(x) = -\nabla_x f_\theta(x)$

$s_\theta(x)$ 加上归一化条件 $\int p_\theta(x) dx = 1$ 可以唯一确定概率密度函数 $p_\theta(x)$

因此，我们可以利用 $s_\theta(x)$ 对 $p_\theta(x)$ 作采样！！

而具体方法就是Langevin Dynamics

现在，我们的任务变成拟合对数概率密度的梯度场

$$\theta^* = \arg \min_{\theta} \mathbb{E}_{p(x)} \left[\frac{1}{2} \|s(x) - s_\theta(x)\|^2 \right]$$


在一定条件下，上式的优化目标可化为(推导见[参考或原文](#))

$$\mathcal{J}_\theta = \mathbb{E}_{p(x)} \sum_{i=1}^n \left[\frac{1}{2} s_\theta^{(i)}(x)^2 + \frac{\partial s_\theta^{(i)}(x)}{\partial x_i} \right] + c$$

Langevin Dynamics Sampling

Assumption:

- 高概率区域， $p(x)$ 值较大，对数密度梯度 $s(x)$ 较小
- 低概率区域， $p(x)$ 值较小，对数密度梯度 $s(x)$ 较大



IDEA: 随机选一个点 x_0 ，逐步将其更新到高概率区域！！

Langevin Dynamics

为此，引入Langevin Equation(用于描述Brown Motion)

$$dx(t) = -\nabla U(x(t))dt + \sigma\sqrt{dt}z_t$$

其中 $z_t \sim \mathcal{N}(0, \mathbf{I})$

令 $dx(t) = x - x'$ ，并记 $dt = \epsilon$ ，我们有

$$x = x' - \nabla U(x(t))\epsilon + \sigma\sqrt{\epsilon}z_t \quad (1)$$

上式即为Langevin Dynamics Sampling的更新过程，会使得数据点往能量最低的区域运动并在该区域附近随机游走。若令

$$U(x) = -\log p(x)$$

则Langevin Sampling可以让数据点 x 移动到概率密度较高处(也就是真实图像)

下面证明Langevin Sampling可以让数据点数据点转移到目标概率分布

若 x 代表大量数据点，则其概率密度函数与时间 t 有关，表示为 $p(x, t)$ ，Langevin采样过程的概率密度函数变化可由Fokker-Planck Equation描述

$$\frac{\partial p(x, t)}{\partial t} = \nabla_x p(x, t)^T \nabla U(x) + p(x, t) \operatorname{div} \nabla U(x) + \frac{1}{2} \sigma^2 \Delta p(x, t) \quad (2)$$

我们希望 $p(x, t)$ 最终达到稳态分布，也就是Boltzman分布

$$p(x, t) = p(x) = \frac{1}{Z} e^{-\frac{U(x)}{T}}$$

代入(2)可得 $T = \frac{\sigma^2}{2}$ ，也就是 $\sigma = \sqrt{2T}$

由于 $p_\theta(x) = \frac{e^{-f_\theta(x)}}{Z_\theta}$ ，因此 $T = 1$ ，于是 $\sigma = \sqrt{2}$ ，此时数据点分布将会趋于稳态Boltzman分布。于是，若选取 $U(x) = -\log p(x)$ ，则最终的稳态Boltzman分布为

$$p(x) = \frac{1}{Z} e^{-\frac{f(x)}{T}}$$

即为所求。因此，只要拟合 $\nabla U(x) = -\nabla \log p(x) = -s(x)$ ，再利用Langevin Dynamics Sampling就可以得到我们想要的的数据点!!!

综上，采样方程如下

$$x_{i+1} = x_i + \epsilon \nabla_x \log p(x) + \sqrt{2\epsilon} z_i, \quad i = 0, 1, \dots, K$$

其中 $\epsilon \rightarrow 0 (K \rightarrow \infty)$, 实际采样时 $\nabla_x \log p(x)$ 由拟合函数 $s_\theta(x) = \nabla_x \log p_\theta(x)$ 代替

退化分布与Noise Conditional Score

现在有了拟合目标, 我们却要面临退化分布问题: 假设图像空间的维度为 d , 但实际图像为一个 $r (r < d)$ 维嵌入子流形, 因此 $p(x)$ 在绝大多数区域上为0, 这样的话score matching在这些点上并不准(因为甚至无法采样到)

解决方法: 在图像空间上加高斯噪声 $\epsilon \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$, 得到 $x' = x + \epsilon$, 对应概率密度函数为 $q_\sigma(x') > 0$

大方差覆盖区域广, 但会破坏原本数据分布; 小方差能保留原本数据分布但覆盖区域小。因此作者采用多强度方差 $0 < \sigma_1 < \dots < \sigma_L$, 对应Score Matching Loss如下

$$\mathbb{E}_{q_\sigma(x)} \frac{1}{2} [\|s_\theta(x, \sigma) - \nabla_x \log q_\sigma(x)\|^2]$$

但是 $q_\sigma(x)$ 无法精确计算, 因此我们做如下转化(DDPM就采用该转化后的Loss)

$$\nabla_x \log q_\sigma(x) = \nabla_x \log [q_\sigma(x|x')p(x')] = \nabla_x \log q_\sigma(x|x')$$

其中

$$\log q_\sigma(x|x') = -\frac{(x - x')^2}{2\sigma^2}$$

因此, Score Matching Loss转化为下面的Noise Conditional Score Matching Loss

$$l(\theta; \sigma_i) = \mathbb{E}_{p(x')} \mathbb{E}_{x \sim \mathcal{N}(x', \sigma_i^2 \mathbf{I})} \left[\frac{1}{2} \left\| s_\theta(x, \sigma_i) + \frac{x - x'}{\sigma_i^2} \right\|^2 \right]$$

集成不同噪声强度得到

$$\mathcal{L}(\theta; \{\sigma_i\}_{i=0}^L) = \frac{1}{L} \sum_{i=1}^L \lambda(\sigma_i) l(\theta; \sigma_i)$$

实验发现 $s_\theta(x, \sigma) \propto \frac{1}{\sigma}$, 因此我们选取 $\lambda(\sigma_i) = \sigma_i^2$

Annealed Langevin Dynamics

Langevin Dynamics如下

$$x_{i+1} = x_i + \epsilon \nabla_x \log p(x) + \sqrt{2\epsilon} z_i, \quad i = 0, 1, \dots, K$$

将Score Function用拟合好的NN替代, 有

$$x_{i+1} = x_i + \epsilon s_\theta(x_i, \sigma_{i+1}) + \sqrt{2\epsilon} z_i, \quad i = 0, 1, \dots, K$$

作者采用的退火Langevin Dynamics如下

Algorithm 1 Annealed Langevin dynamics.

Require: $\{\sigma_i\}_{i=1}^L, \epsilon, T$.

1: Initialize $\tilde{\mathbf{x}}_0$

2: **for** $i \leftarrow 1$ to L **do**

3: $\alpha_i \leftarrow \epsilon \cdot \sigma_i^2 / \sigma_L^2$ $\triangleright \alpha_i$ is the step size.

4: **for** $t \leftarrow 1$ to T **do**

5: Draw $\mathbf{z}_t \sim \mathcal{N}(0, I)$

6: $\tilde{\mathbf{x}}_t \leftarrow \tilde{\mathbf{x}}_{t-1} + \frac{\alpha_i}{2} \mathbf{s}_\theta(\tilde{\mathbf{x}}_{t-1}, \sigma_i) + \sqrt{\alpha_i} \mathbf{z}_t$

7: **end for**

8: $\tilde{\mathbf{x}}_0 \leftarrow \tilde{\mathbf{x}}_T$

9: **end for**

return $\tilde{\mathbf{x}}_T$

也就是取

$$\epsilon = \frac{\alpha_i}{2} = \frac{\epsilon_0 \sigma_i^2}{2\sigma_L^2}$$

直觉上, 一开始, 粒子的视线还很模糊(σ_i 比较大), 但离目标较远, 因此步长可以大一些, 每步都有随机性; 走了T步之后, 视线清晰(σ_i 变小)了一些, 距离目标近了一些,

因此步长减小；如此，走了 $(L-1)T$ 步之后，视线基本清晰无误($\sigma_i \approx 0$)，于是小步微调，直到来到目标分布附近。至此，我们便得到服从 $p_\theta(x) \approx p(x)$ 分布的图像 x

SDE视角下的Diffusion

Ito process

首先引入伊藤过程(Ito process)

$$dx = f(x, t)dt + g(t)dw$$

其中 $dw = \sqrt{dt}z$, $z \sim \mathcal{N}(0, \mathbf{I})$ 为标准Wiener过程， $f(x, t)$ ， $g(t)$ 分别称为漂移因子与扩散因子。该过程亦称为**扩散过程(Diffusion Process)**

可以发现，上式和Langevin Equation的区别在于Langevin Equation的漂移因子与 t 无关，而Ito Process则更一般，与 t 相关。正是这点区别，使得DDPM对应的Ito Process的概率密度函数 $p_t(x)$ 为原数据点分布加上高斯噪声之后的分布，也就是前文提到的 $q_\sigma(x)$

可以证明，上述扩散过程的逆过程亦为扩散过程

$$dx_t = [f(x, t) - g^2(t)\nabla_x \log p_t(x)]dt + g(t)dw$$

其中， dt 为负时间步， $\nabla_x \log p_t(x)$ 称作Score，是唯一的未知量

Score的求解

首先来看Score的表达式

$$\begin{aligned}\nabla_{x_t} \log p_t(x_t) &= \nabla_{x_t} \log [p_{0t}(x_t|x_0)p_0(x_0)] \\ &= \nabla_{x_t} \log p_{0t}(x_t|x_0) \\ &= \nabla_{x_t} \left[-\frac{(x_t - \mu_t)^2}{2\sigma_t^2} \right] \\ &= -\frac{x_t - \mu_t}{\sigma_t^2}\end{aligned}$$

这里 $p_{0t}(x_t|x_0)$ 亦为高斯分布

在DDPM中，有

$$\begin{aligned}\mu_t &= \sqrt{\bar{\alpha}_t} x_0 \\ \sigma_t &= \sqrt{1 - \bar{\alpha}_t}\end{aligned}$$

因此，有

$$\nabla_{x_t} \log p_t(x_t) = -\frac{1}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_t$$

于是，DDPM的Loss为

$$\sum_{t=1}^N (1 - \bar{\alpha}_t) \mathbb{E}_{x_0 \sim p_0(x_0)} \mathbb{E}_{x_t \sim \mathcal{N}(x_0, \sigma_t^2 \mathbf{I})} \left[\|s_\theta(x_t, t) - \nabla_{x_t} \log p(x_t | x_0)\|^2 \right]$$

此即前文提到过的Noise Conditional Score Matching Loss

DDPM的SDE推导

DDPM加噪过程为

$$x_i = \sqrt{1 - \beta_i} x_{i-1} + \sqrt{\beta_i} \epsilon, i = 1, \dots, N$$

$$\text{令 } x(t = \frac{i}{N}) = x_i, \beta(t = \frac{i}{N}) = N\beta_i, \Delta t = \frac{1}{N}, N \rightarrow \infty$$

代入有

$$\begin{aligned}x(t + \Delta t) &= \sqrt{1 - \frac{\beta(t + \Delta t)}{N}} x(t) + \sqrt{\frac{\beta(t + \Delta t)}{N}} \epsilon \\ &= \sqrt{1 - \beta(t + \Delta t) \Delta t} x(t) + \sqrt{\beta(t + \Delta t) \Delta t} \epsilon\end{aligned}$$

取

$$\sqrt{1 - \beta(t + \Delta t) \Delta t} \approx 1 - \frac{1}{2} \beta(t + \Delta t) \Delta t$$

有

$$x(t + \Delta t) = \left[1 - \frac{1}{2} \beta(t + \Delta t) \right] \Delta t x(t) + \sqrt{\beta(t + \Delta t) \Delta t} \epsilon$$

两边减去 $x(t)$ 并令 $\Delta t \rightarrow 0$ 得

$$\begin{aligned} dx(t) &= -\frac{1}{2}\beta(t)x(t)dt + \sqrt{\beta(t)}d\epsilon \\ &= -\frac{1}{2}\beta(t)x(t)dt + \sqrt{\beta(t)}dw \end{aligned}$$

此即DDPM对应的SDE。注意，上面对 β 作了 N 倍放缩主要是为了凑出 Δt

逆向 SDE的求解

Euler-Maruyama Method(欧拉-丸山法)

假设我们有如下SDE

$$dx = a(x_t)dt + b(x_t)dw$$

则可进行如下数值估计

$$x(t + \Delta t) = x_t + a(x_t)\Delta t + b(x_t)\Delta w$$

另外，在数值估计中，有一种优化预测结果的方法，**Predictor-Corrector method(PC方法, 预测-校正法)**，也就是先用一般数值估计求出一个粗解，再利用该粗解用其他方法做进一步修正。在SMLD中，校正的方法即Langevin Dynamics Sampling

Algorithm 3 PC sampling (VP SDE)

```

1:  $\mathbf{x}_N \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
2: for  $i = N - 1$  to  $0$  do
3:    $\mathbf{x}'_i \leftarrow (2 - \sqrt{1 - \beta_{i+1}})\mathbf{x}_{i+1} + \beta_{i+1}\mathbf{s}_{\theta^*}(\mathbf{x}_{i+1}, i + 1)$ 
4:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
5:    $\mathbf{x}_i \leftarrow \mathbf{x}'_i + \sqrt{\beta_{i+1}}\mathbf{z}$  Predictor
6:   for  $j = 1$  to  $M$  do Corrector
7:      $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
8:      $\mathbf{x}_i \leftarrow \mathbf{x}_i + \epsilon_i\mathbf{s}_{\theta^*}(\mathbf{x}_i, i) + \sqrt{2\epsilon_i}\mathbf{z}$ 
9: return  $\mathbf{x}_0$ 

```

注：1. 任何SDE的数值估计法，都可以作为Predictor 2. 任何Score-based MCMC方法，都可以作为Corrector

在DDPM中，Predictor对应模型预测每一步的噪声并更新样本

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \tilde{\sigma}_t z$$

无显式Corrector

Conditional Generation

$$\begin{aligned} \nabla_x \log p(x|y) &= \nabla_x \log p(y|x) + \nabla_x \log p(x) \\ &= \omega [\nabla_x \log p(x|y) - \nabla_x \log p(x)] + \nabla_x \log p(x) \\ &= \underbrace{\omega \nabla_x \log p(x|y)}_{\text{Conditional Score}} + \underbrace{(1 - \omega) \nabla_x \log p(x)}_{\text{Unconditional Score}} \end{aligned}$$