

VAEs

jinhao Zhang

2025 年 12 月 25 日

Variational Autoencoder

如何让模型生成真实数据？一个选择是自编码器 (Autoencoder)，但其编码空间是未结构化的，采样生成的数据点极有可能不真实。基于此，VAE 为编码空间 (潜在空间) 添加了先验结构：标准高斯分布。

Construction of Decoder (Generator)

VAE 将数据生成分为两步：

- 从先验分布 $p(\mathbf{z}) = \mathcal{N}(0, I)$ 中采样潜在变量 $\mathbf{z}$
- 通过解码器 $p_\phi(\mathbf{x}|\mathbf{z})$ 生成数据点 $\mathbf{x}$

则此生成模型可表为：

$$p_\phi(\mathbf{x}) = \int p_\phi(\mathbf{x}|\mathbf{z})p(\mathbf{z})d\mathbf{z} \quad (1)$$

上式不可解，因此使用变分推断做近似。

Construction of Encoder (Inference Network)

我们的数据集中只有真实图像 $\mathbf{x}$ ，如果要直接用(1)来训练模型，由于其不可直接求解，那么需要用 Monte Carlo 方法对积分进行估计：

$$p_\phi(\mathbf{x}) \approx \frac{1}{N} \sum_{i=1}^N p_\phi(\mathbf{x}|\mathbf{z}_i), \quad \mathbf{z}_i \sim p(\mathbf{z}) \quad (2)$$

但是，随机采样的潜在变量 $\mathbf{z}_i$ 大概率与数据点 $\mathbf{x}$ 无关，导致 $p_\phi(\mathbf{x}|\mathbf{z}_i)$ 几乎为都是 0，从而使得估计方差过大，训练难以收敛。一个合理的方案自然是计算出 $\mathbf{z}$ 的后验概率之后再从其中采样：

$$\mathbf{z} \sim p_\phi(\mathbf{z}|\mathbf{x}) = \frac{p_\phi(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{p_\phi(\mathbf{x})} \quad (3)$$

可是其并不可解。因此，VAE 提出使用一个参数化的推断网络 $q_\theta(\mathbf{z}|\mathbf{x})$ 来近似真实后验 $p_\phi(\mathbf{z}|\mathbf{x})$ ：

$$q_\theta(\mathbf{z}|\mathbf{x}) \approx p_\phi(\mathbf{z}|\mathbf{x}) \quad (4)$$

至此，VAE 模型框架构建完毕，下面的问题是如何将其串联起来训练。

Training via the Evidence Lower Bound (ELBO)

有了生成网络和推断网络，直觉上训练流程应该是这样的：

- 从数据集中采样数据点 $\mathbf{x}$
- 通过推断网络 $q_\theta(\mathbf{z}|\mathbf{x})$ 采样潜在变量 $\mathbf{z}$
- 用 MC 方法估计真实数据点的似然 $p_\phi(\mathbf{x}|\mathbf{z})$
- 梯度下降法最大化似然

目标函数为：

$$\mathcal{L}_{\text{Rec}} = -\frac{1}{N} \sum_{i=1}^N \log p_{\phi}(\mathbf{x}|\mathbf{z}_i), \quad \mathbf{z}_i \sim q_{\theta}(\mathbf{z}_i|\mathbf{x}) \quad (5)$$

但是，推断网络没有监督信号，因此我们利用 $\mathbf{z}$ 的先验分布来对其作约束：

$$\mathcal{L}_{\text{Reg}} = \mathcal{D}_{KL}(q_{\theta}(\mathbf{z}|\mathbf{x})\|p(\mathbf{z})) \quad (6)$$

于是，总的目标函数归结为：

$$\mathcal{L}_{\text{VAE}} = -\frac{1}{N} \sum_{i=1}^N \log p_{\phi}(\mathbf{x}|\mathbf{z}_i) + \mathcal{D}(q_{\theta}(\mathbf{z}|\mathbf{x})\|p(\mathbf{z})), \quad \mathbf{z}_i \sim q_{\theta}(\mathbf{z}_i|\mathbf{x}) \quad (7)$$

实际应用时通常取 $N = 1$ 。目标函数得到了，但其真的能达到我们的目标：最大似然吗？这就需要借助一点数学工具了。实际上，上面这个目标是可以严格推导出来的，其本质上为对数似然 $\log p_{\phi}(\mathbf{x})$ 的下界，称为证据下界 (Evidence Lower Bound, ELBO)，具体见如下定理

Theorem 0.0.1. 对于任意数据点 $\mathbf{x} \sim p_{\text{data}}$ ，下列不等式成立：

$$\log p_{\phi}(\mathbf{x}) \geq \mathbb{E}_{\mathbf{z} \sim q_{\theta}(\mathbf{z}|\mathbf{x})} [\log p_{\phi}(\mathbf{x}|\mathbf{z})] - \mathcal{D}_{KL}(q_{\theta}(\mathbf{z}|\mathbf{x})\|p(\mathbf{z})) \quad (8)$$

其中

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{\mathbf{z} \sim q_{\theta}(\mathbf{z}|\mathbf{x})} [\log p_{\phi}(\mathbf{x}|\mathbf{z})] - \mathcal{D}_{KL}(q_{\theta}(\mathbf{z}|\mathbf{x})\|p(\mathbf{z})) \quad (9)$$

称为证据下界 (ELBO)。

证明.

$$\log p_{\phi}(\mathbf{x}) = \log \int p_{\phi}(\mathbf{x}, \mathbf{z}) d\mathbf{z}, \quad \text{引入潜在变量 } \mathbf{z} \quad (10)$$

$$= \log \int q_{\theta}(\mathbf{z}|\mathbf{x}) \frac{p_{\phi}(\mathbf{x}, \mathbf{z})}{q_{\theta}(\mathbf{z}|\mathbf{x})} d\mathbf{z}, \quad \text{引入推断网络 } q_{\theta}(\mathbf{z}|\mathbf{x}) \quad (11)$$

$$= \log \mathbb{E}_{q_{\theta}(\mathbf{z}|\mathbf{x})} \left[\frac{p_{\phi}(\mathbf{x}, \mathbf{z})}{q_{\theta}(\mathbf{z}|\mathbf{x})} \right], \quad \text{期望形式方便后续处理} \quad (12)$$

$$\geq \mathbb{E}_{q_{\theta}(\mathbf{z}|\mathbf{x})} \left[\log \frac{p_{\phi}(\mathbf{x}, \mathbf{z})}{q_{\theta}(\mathbf{z}|\mathbf{x})} \right], \quad \text{Jensen 不等式} \quad (13)$$

$$= \mathbb{E}_{q_{\theta}(\mathbf{z}|\mathbf{x})} \left[\log \frac{p_{\phi}(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{q_{\theta}(\mathbf{z}|\mathbf{x})} \right], \quad \text{引入生成网络 } p_{\phi}(\mathbf{x}|\mathbf{z}) \quad (14)$$

$$= \mathbb{E}_{\mathbf{z} \sim q_{\theta}(\mathbf{z}|\mathbf{x})} [\log p_{\phi}(\mathbf{x}|\mathbf{z})] - \mathcal{D}_{KL}(q_{\theta}(\mathbf{z}|\mathbf{x})\|p(\mathbf{z})), \quad \text{化为 ELBO} \quad (15)$$

□

Gaussian VAE

标准的 VAE 将推断网络和生成网络都建模为高斯分布：

$$q_{\theta}(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mu_{\theta}(\mathbf{x}), \text{diag}(\sigma_{\theta}^2(\mathbf{x}))) \quad (16)$$

$$p_{\phi}(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mu_{\phi}(\mathbf{z}), \sigma^2 \mathbf{I}) \quad (17)$$

此时，损失函数可化简为：

$$\mathcal{L} = \underbrace{\mathbb{E}_{\mathbf{z} \sim q_{\theta}(\mathbf{z}|\mathbf{x})} \left[\frac{1}{2\sigma^2} \|\mathbf{x} - \mu_{\phi}(\mathbf{z})\|^2 \right]}_{\text{重构误差}} + \underbrace{\mathcal{D}_{KL}(q_{\theta}(\mathbf{z}|\mathbf{x})\|p(\mathbf{z}))}_{\text{KL 正则}} \quad (18)$$

其中的 KL 正则可闭式计算。

Blurry Generations in VAEs

考虑 Gaussian VAE，假设编码器固定为 $q_{\text{enc}}(\mathbf{z}|\mathbf{x})$ ，解码器为 $p_{\phi}(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mu(\mathbf{z}), \sigma^2 \mathbf{I})$ ，则 KL 正则项消去，VAE 的总目标为优化：

$$\mathcal{L} = \mathbb{E}_{p_{\text{data}}(\mathbf{x})q_{\text{enc}}(\mathbf{z}|\mathbf{x})} [\|\mathbf{x} - \mu(\mathbf{z})\|^2] \quad (19)$$

对 μ 求偏导并令其为 0：

$$\frac{\partial \mathcal{L}}{\partial \mu} = \frac{\partial}{\partial \mu} \mathbb{E}_{p_{\text{data}}(\mathbf{x})q_{\text{enc}}(\mathbf{z}|\mathbf{x})} [\|\mathbf{x} - \mu(\mathbf{z})\|^2] \quad (20)$$

$$= \int p_{\text{data}}(\mathbf{x})q_{\text{enc}}(\mathbf{z}|\mathbf{x}) \frac{\partial}{\partial \mu} \|\mathbf{x} - \mu(\mathbf{z})\|^2 d\mathbf{x}d\mathbf{z} \quad (21)$$

$$= 2 \int p_{\text{data}}(\mathbf{x})q_{\text{enc}}(\mathbf{z}|\mathbf{x}) (\mu(\mathbf{z}) - \mathbf{x}) d\mathbf{x}d\mathbf{z} \quad (22)$$

$$= 2 \int p(\mathbf{z})q_{\text{enc}}(\mathbf{x}|\mathbf{z}) (\mu(\mathbf{z}) - \mathbf{x}) d\mathbf{x}d\mathbf{z} \quad (23)$$

$$= 2 \int p(\mathbf{z})d\mathbf{z} q_{\text{enc}}(\mathbf{x}|\mathbf{z}) (\mu(\mathbf{z}) - \mathbf{x}) d\mathbf{x} \quad (24)$$

$$= 2 \int p(\mathbf{z}) (\mu(\mathbf{z}) - \mathbb{E}_{q_{\text{enc}}(\mathbf{x}|\mathbf{z})}[\mathbf{x}]) d\mathbf{z} \quad (25)$$

$$\triangleq 0 \quad (26)$$

于是可以得到最优解：

$$\mu^*(\mathbf{z}) = \mathbb{E}_{q_{\text{enc}}(\mathbf{x}|\mathbf{z})}[\mathbf{x}] \quad (27)$$

利用 Bayes 公式可化为：

$$\mu^*(\mathbf{z}) = \mathbb{E}_{q_{\text{enc}}(\mathbf{x}|\mathbf{z})}[\mathbf{x}] \quad (28)$$

$$= \int \frac{p_{\text{data}}(\mathbf{x})q_{\text{enc}}(\mathbf{z}|\mathbf{x})}{p(\mathbf{z})} \mathbf{x} d\mathbf{x} \quad (29)$$

$$= \frac{1}{p(\mathbf{z})} \int p_{\text{data}}(\mathbf{x})q_{\text{enc}}(\mathbf{z}|\mathbf{x}) \mathbf{x} d\mathbf{x} \quad (30)$$

$$= \frac{1}{p(\mathbf{z})} \mathbb{E}_{p_{\text{data}}}[q_{\text{enc}}(\mathbf{z}|\mathbf{x})\mathbf{x}] \quad (31)$$

$$= \frac{\mathbb{E}_{p_{\text{data}}}[q_{\text{enc}}(\mathbf{z}|\mathbf{x})\mathbf{x}]}{\mathbb{E}_{p_{\text{data}}}[q_{\text{enc}}(\mathbf{z}|\mathbf{x})]} \quad (32)$$

上式本质上就是以 $q_{\text{enc}}(\mathbf{x}|\mathbf{z})$ 为权重，对样本点 $\mathbf{x}$ 做的加权平均。考虑这样一种情况：存在不同的两个数据点 $\mathbf{x}, \mathbf{x}'$ ，其支撑集的交不空，则 $\mu^*(\mathbf{z})$ 会对多个可能不相关的数据点作平均，导致模糊与伪影。